

Interpretowalność i Wyjaśnialność Uczenia Maszynowego - projekt 1

Bartosz Pokora, Franciszek Saliński





Cele projektu


- Stworzenie dwóch modeli przewidujących default:
 - Interpretowalny (**Regresja logistyczna**)
 - Black box (**Las losowy**)
- Zastosowanie technik pozwalających na zrozumienie i wyjaśnienie procesu decyzyjnego tych modeli
- Kalibracja modeli tak, aby średnie prawdopodobieństwo defaultu wynosiło **4%**
- Optymalizacja progu operacyjnego i stworzenie **tabeli ratingowej**




Dane i modele







EDA i przetwarzanie danych

- Niezbalansowana zmienna celu
- Wyrzucenie kolumn, w których występowała praktycznie jedna wartość
- Podział na zbiór treningowy i testowy (70/30)
- Występujące wartości inf i braki
- Pipeline:
 - SimpleImputer
 - QuantileClipper
 - One-Hot Encoder
 - StandardScaler



Correlation Matrix







Optymalizacja hiperparametrów



- Zarówno dla regresji logistycznej, jak i lasu losowego optymalizowaliśmy metrykę ROC AUC, używając optymalizacji bayesowskiej (Optuna)
- Modele uzyskały na zbiorze testowym / treningowym AUC:
 - Regresja logistyczna: **0.71 / 0.82**
 - Las losowy: **0.74 / 0.82**



Kalibracja



Reliability diagram dla regresji logistycznej vs lasu losowego






Optymalizacja progu decyzyjnego






Model optymalizacja kosztów


- True Positive (TP): 0 zł - poprawnie odrzucony wniosek niewypłacalnego klienta
- False Negative (FN): 100 000 zł - koszt udzielenia kredytu niewypłacalnemu klientowi
- False Positive (FP): 0 zł - odrzucenie wniosku wypłacalnego klienta
- True Negative (TN): -10 000 zł - zysk z udzielenia kredytu wypłacalnemu klientowi



Logistic Regression (threshold=0.1250)



Random Forest (threshold=0.0650)





Optymalne progi


- Regresja logistyczna wybiera wyższy próg (0.1250), co prowadzi do bardziej konserwatywnej strategii z wyższą stopą akceptacji (92.78%). Model akceptuje więcej klientów, ale przy tym generuje więcej błędów FN (39 przypadków nieuchwyconych defaultów).
- Las losowy wybiera niższy próg (0.0650), co skutkuje bardziej restrykcyjną polityką kredytową ze stopą akceptacji 80.56%. Model jest bardziej ostrożny, łapiąc więcej rzeczywistych defaultów (30 TP vs 14 dla LR), ale odrzucając przy tym więcej dobrych klientów (145 FP vs 51 dla LR).

Mapowanie na ratingi




Rating	Zakres PD	Opis
AAA	0.00% - 0.03%	Wyjątkowo silna zdolność kredytowa
AA	0.03% - 0.10%	Bardzo silna zdolność kredytowa
A	0.10% - 0.40%	Silna zdolność kredytowa
BBB	0.40% - 1.50%	Wystarczająca zdolność kredytowa
BB	1.50% - 6.00%	Spekulacyjna, podwyższone ryzyko
B	6.00% - 20.00%	Wysoce spekulacyjna
CCC	20.00% - 50.00%	Istotne ryzyko defaultu
CC	50.00% - 80.00%	Bardzo wysokie ryzyko defaultu
C	80.00% - 100.00%	Bliski defaultu

Rozkład ratingów - Regresja Logistyczna



Rozkład ratingów - Las Losowy





Wyjaśnialność





SHAP, feature importance, permutation importance



- Aby wyjaśnić decyzje modeli stworzyliśmy wykresy, które dla obu modeli pokazują:
 - Istotność zmiennych przez miary pochodzące z modeli (współczynniki w LR i feature importance w RF)
 - Permutation importance
 - Mean absolute SHAP value i beeswarm pokazujące, które zmienne miały największy wpływ na podejmowane decyzje i jaki był ten wpływ
 - Kilka lokalnych case study SHAP



Wyjaśnienia globalne dla LR




Wyjaśnienia globalne dla RF







LR, wyjaśnienie lokalne z wysokim ryzykiem



LR, wyjaśnienie lokalne ze średnim ryzykiem




LR, wyjaśnienie lokalne z niskim ryzykiem







RF, wyjaśnienie lokalne z wysokim ryzykiem



RF, wyjaśnienie lokalne ze średnim ryzykiem



RF, wyjaśnienie lokalne z niskim ryzykiem





Dziękujemy za uwagę:)